Prédiction de l'admission au concours de l'Agrégation par K-Nearest Neighbors

Réalisé par PHILIBERT Thibault & AZAIS Thibault

Date : 11/02/2026

Résumé :

Ce rapport présente la démarche de modélisation prédictive visant à anticiper la réussite au concours de l'agrégation de droit. Le modèle basé sur l'algorithme des K-Nearest Neighbors (KNN) s'appuie sur la selection de trois variables explicatives : la distance géographique entre l'université de soutenance et Paris (***Distance_Univ_soutenance-paris***) ; le score de publications (***Publication***) et les éditeurs de la thèse de l'individu (***Editeur_de_la_these***).

Après une procédure d'optimisation par la cross validation en 5 plis (5 folds), la configuration retenue privilégie la stabilité avec les hyperparamètres suivants : un voisinage K = 14, une pondération par la distance et une métrique Euclidienne (p=2).

Notre approche permet l'obtention d'un score de validation croisée (CV) moyen de 69.66% avec un écart type de 2.7%, performance confirmée par une accuracy de 70.15% sur le jeu de test.

Le concours de l'agrégation de droit est un examen réputé pour sa sélectivité et sa complexité, mêlant excellence académique, reconnaissance par les pairs et facteurs géographiques implicites.

L'objectif de notre projet est de développer un modèle prédictif qui puisse anticiper la réussite d'un individu candidat au concours de l'agrégation de droit en se basant sur des données historiques.

La problématique centrale se trouve dans l'hétérogénéité des données disponibles : comment produire un résultat binaire à partir d'un mélange de distances géographiques, de scores de publications et de noms d'éditeurs ?

Notre démarche s'est concentrée sur la construction d'un pipeline de traitement étant capable de nettoyer les données brutes pour alimenter notre algorithme de classification supervisée : le **K-Nearest Neighbors** (KNN).

Le rapport détaille les défis techniques rencontrés et les solutions retenues pour maximiser la fiabilité du modèle proposé.

Exploration et nettoyage

La phase d'exploration des données a été importante pour identifier les biais potentiels et les obstacles à la modélisation.

Le jeu de données de base avait de nombreuses variables. Une analyse de corrélation (figure 4 en annexe) nous a permis d'isoler trois facteurs prédictifs :

- ***Distance_Univ_soutenance-paris*** : Cette variable a montré une tendance structurelle forte (Figure 3). Les candidats ayant soutenu leur thèse à proximité des centres académiques parisiens sont surreprésentés parmi les admis. Notre constat propose une corrélation entre centralité académique et réussite au concours.
- ***Publication*** : Si le score de publications est un indicateur d'excelence académique, sa distribution est très asymétrique. La majorité des candidats sont massivement proche de zéro, tandis qu'une minorité en possède un nombre très élevé.
- ***Editeur_de_la_these*** : C'est le discriminant le plus fort (figure 2). Certains éditeurs prestigieux affichent des taux de réussite supérieur à 50% contre moins de 10% pour des éditeurs plus petits ou l'absence de publication.

Nous avons identifier un obstacle majeur sur certaines variables : la présence de valeurs extrêmes. Certaines observations présentent des distances nulles ou très grandes, ou un score de publications disproportionné.

Dans un algorithme KNN, se basant sur la distance euclidienne ou de Manhattan entre les points, les valeurs aberrantes écrasent les autres variables. Le candidat ayant un score de publication anormalement élevé serait très loin de tous les autres, faussant le calcul des voisins.

Notre solution a été l'utilisation d'un RobustScaler. Cette technique utilise la médiane et l'écart interquartile pour normaliser les données. Les profils atypiques sont gérés sans déformer la distribution de la majorité des individus. L'utilisation d'un MinMaxScaler aurait été très sensible aux outliers.

Feature Engineering

L'étape la plus complexe du projet concerne le traitement de la variable catégorielle ***Editeur_de_la_these***.

Cette variable contient des dizaines de noms d'éditeurs différents. Une approche classique type OneHotEncoding (création d'une colonne par éditeur) aurait généré un jeu de données avec de nombreuses dimensions. Cependant le KNN perd en efficacité lorsque le nombre de dimensions augmente car les distances entre les points s'uniformisent.

Afin de contourner le problème, nous avons transformé la variable qualitative en 3 indicateurs binaires :

- ***Is_Top*** : l'éditeur est historiquement associé à la réussite ?
- ***Is_Bottom*** : l'éditeur est-il associé à l'echec ?
- ***Is_NonPublie*** : La thèse est-elle non publiée ?

Mais comment décider si un éditeur est top s'il n'a publié qu'un seul candidat (qui a réussi par exemple) ? Pour éviter ce biais, nous avons mené une étude de sensibilité (Figure 6) avec différents seuils de filtrage. En dessous de 10 candidats, le modèle apprenait du bruit, mais nous avons une stabilisation de la performance en ne considérant que les éditeurs ayant présenté au moins 16 candidats dans l'historique.

Avec ce seuil de 16, le modèle ne considère comme top ou bottom que les éditeurs fiables, traitant les petits éditeurs rares comme des éditeurs moyens (valeur 0 dans les 3 variables binaires créées), ce qui est une position plus prudente.

Modélisation et optimisation

L'admission semble suivre une logique d'appartenance à des profils types de candidats. Le KNN permet de classer les observations en regardant si ses caractéristiques le placent dans le voisinage de candidats ayant réussi par le passé.

Pour éviter le piège d'over-fitting (un modèle qui apprend par cœur les données d'entrainement mais échoue sur les nouvelles données), nous avons splitté en deux le jeu de données sous la forme 80% pour l'entrainement et 20% pour le test (isolé jusqu'à la fin du projet).

Nous avons utilisé la Cross Valdiation à 5 plis. Le modèle est entrainé 5 fois sur des sous parties différentes du train split, garantissant que le score de performance n'est pas du à un coup de chance.

Nous avons utilisé une GridSearchCV pour tester les combinaisons d'hyperparamètres (voisins K de 1 à 30, pondérations, métriques). Mais nous n'avons pas seulement choisi le modèle avec le meilleur score moyen. Nous avons mis en place une règle de décision basée sur la stabilité : **Parmi les modèles performants (écart inférieur à 0.5% du score max), il faut choisir celui qui présente l'écart-type le plus faible.**

Notre approche permet d'écarter des configurations instables mais qui performent bien au profit d'un modèle beaucoup plus robuste.

Analyse des résultats

Le processus de sélection a convergé vers les hyperparamètres suivants :

- ***Nombre de voisin K = 14*** : Ce nombre est suffisamment élevé pour lisser les irrégularités mais assez faible pour garder une sensibilité aux spécificités locales.
- *Pondération = 'Distance'* : Contrairement à 'Uniform', donner plus de poids aux voisins très proches semble optimisé. Cela signifie qu'un voisin très similaire au candidat a plus d'influence sur la prédiction que des voisins plus éloignés.
- ***Métrique = Euclidienne (p=2)***

Notre modèle atteint une précision finale (Accuracy) de **70.15%** sur le jeu de test, cela montre plusieurs choses :

- Le score sur test (70.15%) est quasiment identique au score moyen de validation (**69.66%**). Cela montre l'absence de sur-apprentissage. Le modèle est généralisable.
- Le modèle parvient à bien discriminer les profils. Il identifie correctement la majorité des vrai positifs (vrais admis) et des vrais négatifs (vrais non-admis).
- Les erreurs (faux positifs et faux négatifs) ne sont pas forcement des échecs mais une part imprévisible du concours. Un individu peut avoir un profil excellent académiquement parlant mais échouer l'agrégation et inversement.

Conclusion

Notre projet a permit la construction d'un modèle prédictif fiable qui est capable d'estimer les chances de réussite avec une précision de 70% ce qui est significatif en prenant compte du faible nombre de variables utilisées.

Une grande force de notre travail se place dans la rigueur du feature-engineering et la stratégie de sélection par stabilité plutôt que par performance pure.

Annexes

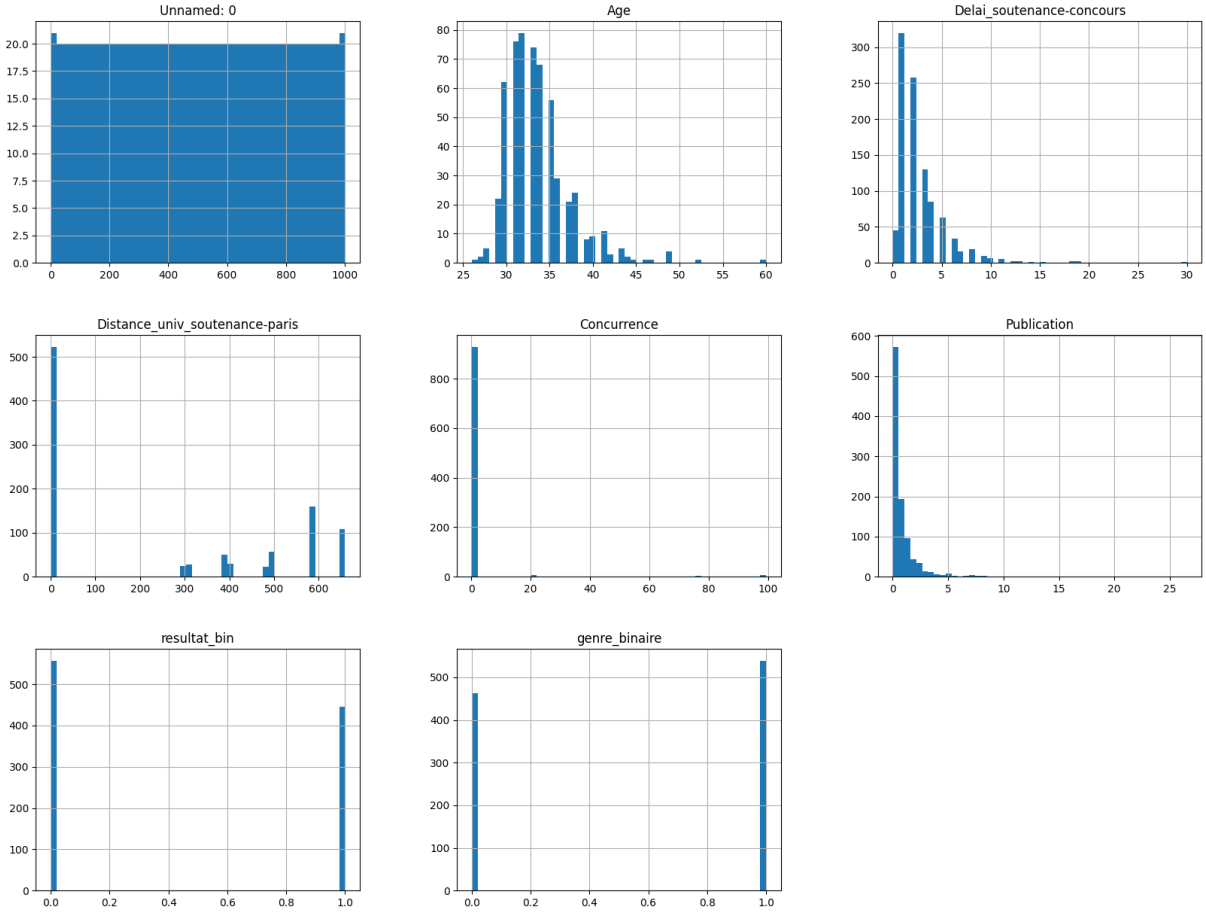


Figure 1 Histogramme des variables numériques

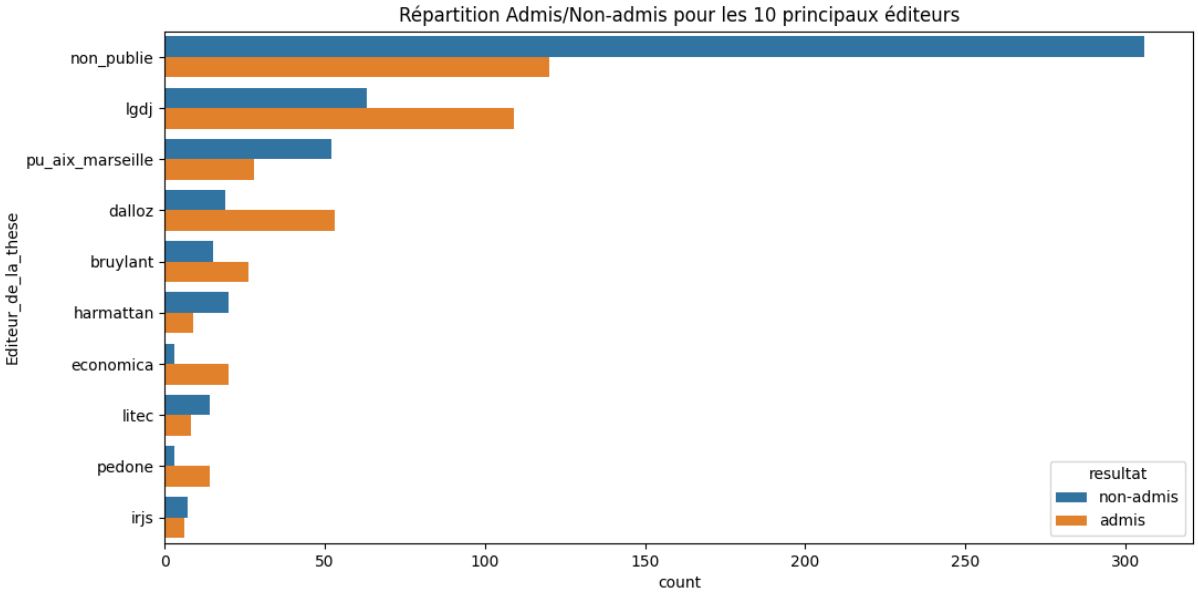


Figure 2 Répartition Admis & Non-Admis pour le top 10 editeurs

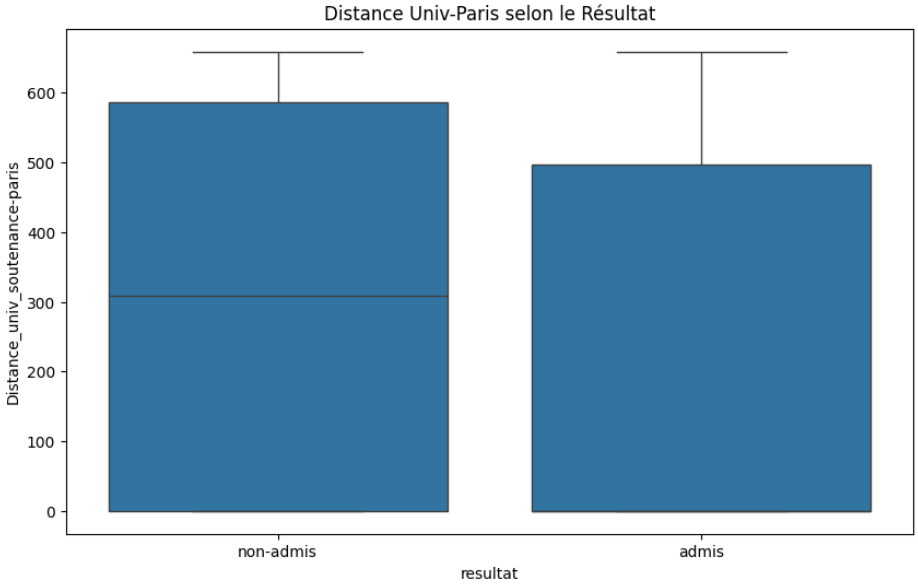


Figure 3 BoxPlot distance université de soutenance à Paris selon le résultat

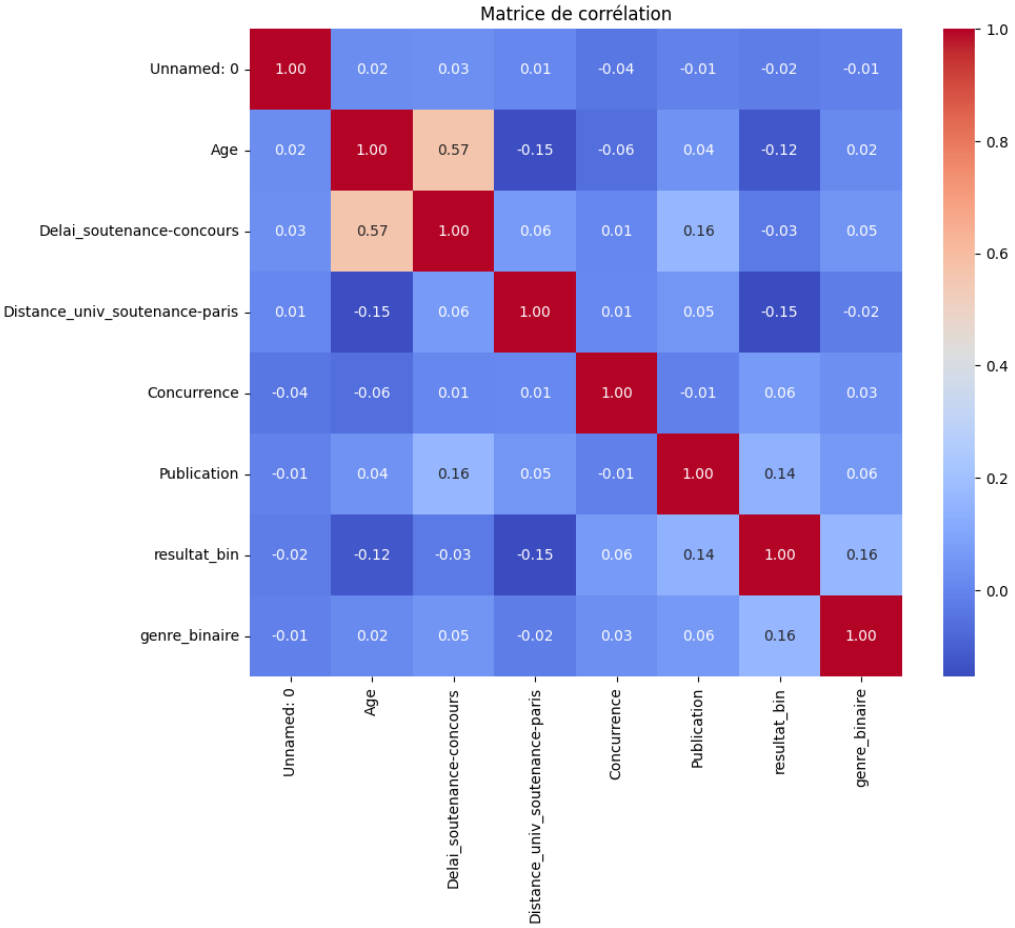


Figure 4 Matrice de correlation

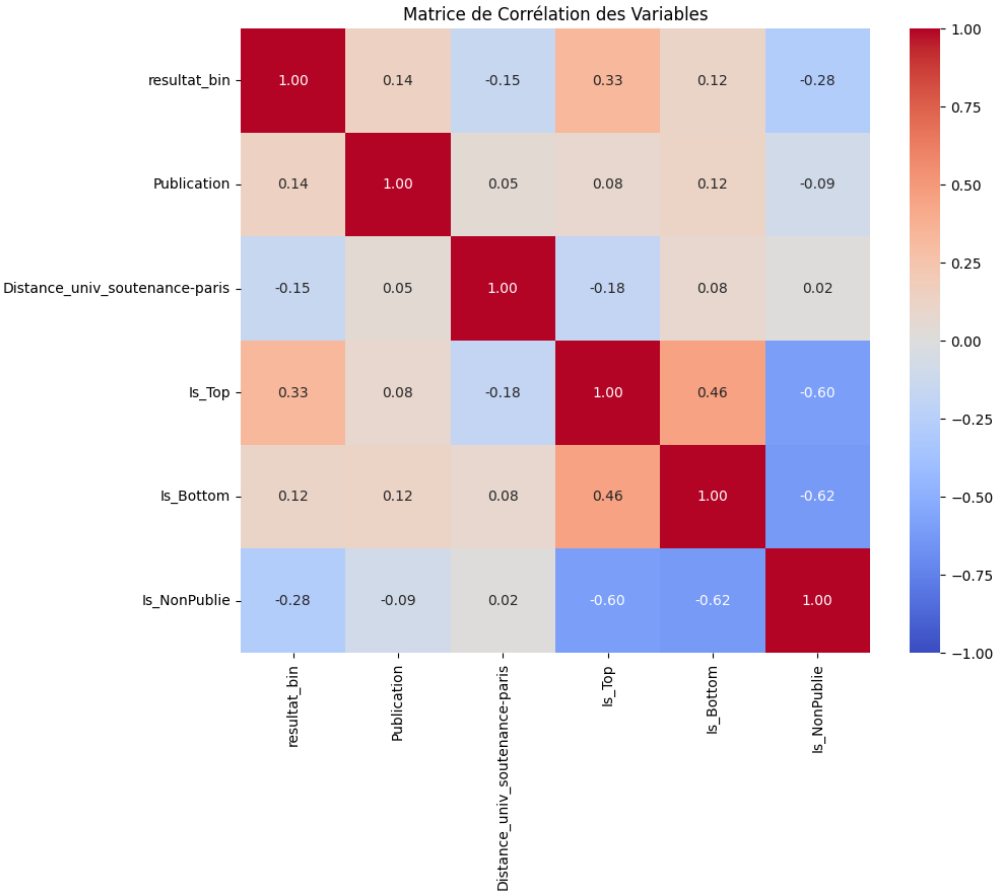


Figure 5 Matrice de corrélation avec découpage de la variable éditeur_de_la_these

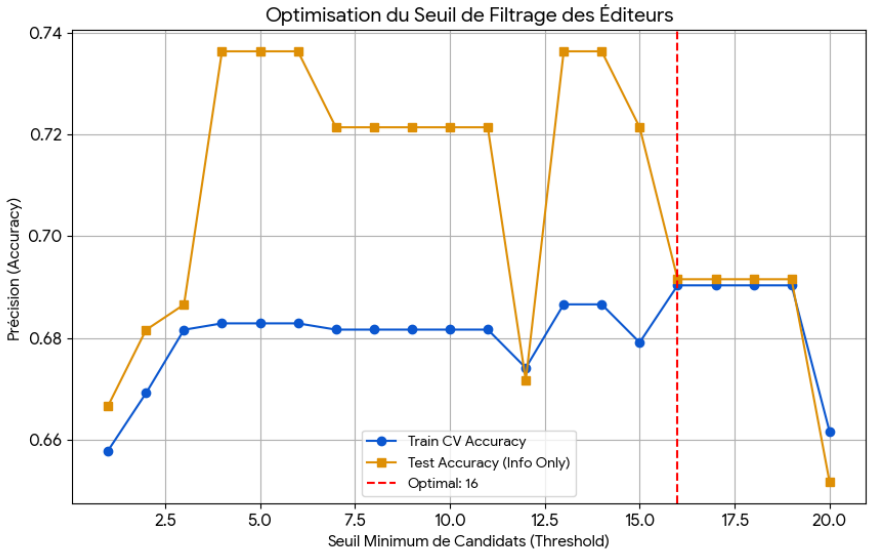


Figure 6 Optimisation seuil des editeurs